

LLMを利用した2038年問題へのアプローチ

大江 秀幸^{1,a)} 松下 誠^{2,b)} 井上 克郎^{3,c)}

概要：C言語で開発された多くのITシステムにおいて、2038年問題への対応として時刻データ（time_t型）の64ビット化が進められている。しかし、単なる型の拡張だけでは対策として不十分である。ポインタを経由した間接参照や暗黙的な型変換、さらに32ビットの時刻上限を前提としたロジックなど、コードの意味論に依存する欠陥を含めて網羅的に特定することは、従来の静的解析ツールやコンパイラ警告だけでは困難である。本研究では、2038年問題を引き起こすエポックオーバーフロー欠陥（EOD）をこれまでの調査結果に基づいてモデル化し、大規模言語モデル（LLM）を用いて欠陥箇所を高精度に検出する手法を提案する。FreeBSDに含まれる実ソースコードを対象とした評価実験の結果、Google Gemini 3.1 Proを用いた場合、ゴールドスタンダードに対するF1スコア0.94という高い精度で欠陥箇所の候補を特定できることを確認した。本手法により、人手によるコードレビューの負担を低減し、効率的で信頼性の高いプログラム保守の実現が期待できる。

キーワード：2038年問題、プログラム保守、データ幅変更、大規模言語モデル

1. はじめに

2038年問題は、1970年1月1日0時0分（UTC）を起点として毎秒カウントアップされるUnix時間が、32ビット符号付き整数の最大値（2,147,483,647）を超える、2038年1月19日3時14分7秒（UTC）に顕在化する問題である。この根本原因は、Unix時間[?]を扱うtime_t型[?]が従来の環境において32ビット符号付き整数として定義されているため、当該時刻において整数オーバーフローが発生することにある。

現在、多くの実装や処理系においてtime_t型の64ビット化が進められている。しかし、型定義の変更のみでは対策として不十分である。以下に、データと制御の両観点から、64ビット化に伴い考慮すべき問題点を挙げる。

1.1 データ観点での問題点

time_t型で表現される値のすべてのデータフローにおいて、32ビットの正の最大値を超える値が正しく扱われることを保証する必要がある。ここには、C言語特有の課題が介

在する。例えばC言語においてデータ幅（型）を変更する際、単純な変数名の検索・置換のみでは網羅できない。ポインタを経由した間接参照（エイリアシング）や暗黙的な型変換によってメモリ領域が操作される可能性を考慮し、プログラム全体のデータフローを追跡・確認しなければならないためである。

さらに、ターゲット環境のデータモデル（LP64やLLP64など）への依存にも注意が必要である。例えば、64ビット化されたtime_t型の値をlong型変数に代入する場合、LP64モデルではデータの欠落は発生しないが、LLP64モデルではlong型が32ビットであるため、値の切り詰めによる情報の欠落が発生する。

1.2 制御観点での問題点

32ビットのtime_t型がオーバーフローすることを前提として実装された回避処理（ワークアラウンド）がプログラム内に存在する場合、64ビット化によってその制御自体が新たなバグを引き起こす恐れがある。また、時刻データを32ビット長であると暗黙的に仮定し、固定長のビットマスクやシフト演算を行っている制御も、意図しない挙動の要因となる。

一方で、64ビット化されたtime_t型変数から、より小さなビット幅の整数型（32ビット整数など）へのダウンキャスト（代入処理）が存在したとしても、事前の上限値チェック等により代入先のビット数以下に値が制限される制御が確立されていれば、プログラム上の問題は起こらない。

¹ 羽衣国際大学現代社会学部
Hagoromo University of International Studies, 1-89-1 Hamadera Minamimachi, Nishi Ward, Sakai, Osaka, Japan
² 大阪医療大学医療看護学部
Osaka University of Medical Sciences, 2-14-19 Yada, Higashisumiyoshi Ward, Osaka, Osaka, Japan
³ 立命館大学情報理工学部
Ritsumeikan University, 2-150 Iwakura-cho, Ibaraki, Osaka, Japan
a) hooe@hagoromo.ac.jp
b) m.m3578@osaka-iryou.ac.jp
c) inoue-k@fc.ritsume.ac.jp

整数オーバーフローを定義から排除するためのものである。論理和 $\text{Trunc} \vee \text{Bound}$ は、2038 年問題の根本原因を「型幅に起因する値の切り詰め」と「コードに埋め込まれた暦境界」という二つの異なる類型に明確に分離している。いずれも環境の 64 ビット化 (time_t 型の拡張など) のみでは解消されず、前者は代入や間接参照の過程で依然として型幅のミスマッチ (切り詰め) が発生するのに対し、後者は型幅に依存せず比較・評価ロジックそのものに起因して問題が存続するという性質の違いが、この分離の背景にある。最後に Obs は、デッドコードや後続で上書きされる無害な値を欠陥から除外し、検出器の適合率を評価する際に有効となる。式??の関係を図??に図示する。

2.2.1 二類型の実例

式??の論理和部分、すなわち値の切り詰めと暦に関する境界値の評価について、実在の C コード (FreeBSD[?]) の date 系の時刻処理を単純化したもの) を用いて例示する。

例 1: 切り詰め型

```
static int domktime(struct tm *t, char type)
{
    time_t ret;
    ret = mktime(t); /* 返回值型 time_t */
    return ret;      /* time_t -> int */
}
```

ret は mktime() の返回值であり時刻要素から派生するため Orig が成立する。return ret; において time_t 型の値を int 型で return している。64 ビット time_t 環境では 32 ビットの int 型よりビット幅が広く、かつ 2038 年以降の時刻値は int の表現可能範囲に収まらないため、Trunc が成立する。この返却値は呼び出し側の分岐処理などに利用され、上書きされることはないため、Obs も成立する。本欠陥の原因は time_t 型の幅ではなく、返回值の型指定の縮小にあるため、 time_t 型を 64 ビット化しても問題として残留する。

例 2: 境界型

```
while ((ret = mktime(t)) == -1
    && t->tm_year > 68
    && t->tm_year < 138) {
    /* 失敗時に年を補正して再試行 */
}
```

$t \rightarrow \text{tm_year}$ および mktime() の結果は時刻情報に起源を持つため、Orig が成立する。定数 138 (tm_year は 1900 年起点ゆえ西暦 2038 年を表す) が暦的上限を表し、 tm_year が 138 以上となる時刻でループ条件が偽となり補正処理に到達しないため Bound が成立する。補正の有無は後続の時刻処理

結果に影響するため Obs も成立する。本欠陥の原因はコードに埋め込まれた「暦に関する知識」にあるため、 time_t 型を 64 ビット化しても定数 138 が残る限り問題は解消されない。

これら二つの例は、いずれも単なる「64 ビット化」では解消しない問題であるが、検出手法の観点からは大きな違いがある。例 1 は型システムに起因するため、静的な型情報から比較的容易に検出可能である。一方、例 2 は定数に込められた暦的な意味 (セマンティクス) の解釈を要する。このことから、提案手法の適用範囲を以下のように決める。

2.2.2 解ける範囲の画定

式??のうち、2038 年問題につながる恐れのある Orig $\wedge$ ($\text{Trunc} \vee \text{Bound}$) を満たす候補箇所をまずは検出し、Obs の最終的な判定は人間のレビューに委ねる。そのレビューコストを削減するために候補集合の「適合率」を可能な限り高める方針とし、候補箇所の検出を LLM によって自動化し、最終判定を行う人間のレビューについても LLM で支援することを提案する。Obs の厳密な判定は一般に困難であるため (詳細は??節で述べる)、本稿では問題解決の完全な自動化は目指さず、問題を「機械的に絞り込める部分」と「人間が判断する部分」とに分割する。この方針のもとでは真の再現率は測定できないため、本稿では適合率を重視する。ただしモデル間の比較のため、??節にて述べるゴールドスタンダードに対する相対的な再現率および F1 スコアも併せて報告する。

3. 提案手法

前章で示した通り、2038 年問題の解決には人間が判断する部分が残る。本研究ではこの部分に LLM を適用し、問題解決の省力化を目指した。近年の LLM は、自然言語による対話形式で多様な問いへの応答を生成できるだけでなく、プログラミング言語の解析においても実用レベルの精度を示すようになってきている [?, ?]。本研究では、2038 年問題の検出に LLM を適用することで、以下のメリットが得られることを期待している。

- 修正が必要な箇所を簡単なプロンプトによって発見できる。
- 各データ型の実際のビット幅を仮定することなく、実装依存箇所についても自然言語の文脈を読み解いて発見できる。
- コンパイラ警告として顕在化しないロジック上の制約についても、コードの意味理解に基づいて指摘できる可能性がある。

指定したC言語のソースコードから、time_tが64ビットであっても発生する「2038年問題」の根本原因となる箇所を抽出し、以下に指定するJSON形式で出力せよ。出力はJSONのみとし、説明文を付けないこと。

【抽出条件】

- ・time_tが64ビット化されていても発生する「ロジック上の制限」を抽出すること。
- ・加えて、time_t型とint型やlong型のデータ間でオーバーフローやデータの切り詰めが発生する箇所を抽出すること。
- ・実装依存の場合は、その旨を問題の種類に明記すること。
- ・根本原因を修正することで不具合が発生しなくなる箇所は、抽出しないこと。
- ・添付のソースコード以外の情報は解答に利用しないこと。

【JSON形式】

```
{  "issues": [
    {
      "line": <問題となる命令文>,
      "type": <問題の種類>,
      "reason": <1文で理由>,
      "fix": <1文で修正案>
    }
  ]
}
```

図2 プロンプト

Fig. 2 Prompt.

3.1 EODの検出手順

LLMを活用したEODの検出手順は次のとおりである。最初に、専用アプリケーションやWebブラウザ経由で利用可能なLLMの中から、使用するモデルを選択する。本手法では、C言語ソースコードを1ファイルずつ入力し、個別に検出を各モデルにつき1回行う。選択したモデルのサービス画面において、図??のプロンプトを記述し、解析対象のC言語ソースコードを添付して処理を開始する。




図3 Google Gemini 3.1 Pro への適用例

Fig. 3 Application Example for Google Gemini 3.1 Pro.

なお、対象ソースコードは最大でも1ファイルあたり約1000行（概ね数千～1万トークン）であり、各LLMの最大コンテキスト長（最小のモデルでも128,000トークン以上）に十分収まる。このためファイルの分割や要約は不要であり、コンテキスト長に起因する入力の切り詰めや精度低下を、本実験では考慮しない。

図??に Google Gemini 3.1 Pro での実験の様子を、また図??に LLM 適用結果の例を示す。

3.2 LLM 利用時の留意点

一方で、LLMをソースコード解析に利用するにあたっては、以下の点に留意する必要がある。第一に、どのモデルを利用するかである。LLMの種類は急速に増加しており、モデル毎にコード理解能力や得意分野が異なる。第二に、どのプロンプトを与えるかである。プロンプト設計（プロンプトエンジニアリング）はLLMの応答品質を大きく左右する[?]。第三に、モデルとプロンプトの組合せが適切かである。第四に、LLMの応答に内在する「揺らぎ」（確率的サンプリングや浮動小数点演算の非決定性に起因する応答のばらつき）をどう扱うかである[?]。本稿ではこれらのうち主としてモデル選択の観点から比較評価を行う。

4. 評価実験

4.1 実験の概要

本実験では、EODを含むことが事前にわかっている5本のC言語ソースコードを対象に、複数のLLMがどの程度の精度で該当箇所を検出できるかを評価する。プロンプトは全モデル共通とし、各モデルの出力結果を真陽性（TP）と偽陽性（FP）に分類して比較した。なお、??節で述べた「機械的に絞り込める部分」と「人間が判断する部分」への分割のうち、本実験で評価するのはLLMによって自動化できる候補検出の部分であり、人間が最終的に判断する部分は評価対象に含めない。




図4 適用結果の例

Fig. 4 Examples of LLM Application Results.

4.2 対象ソースコード

対象ソースコードは、既報の研究で用いた FreeBSD13.2-RELEASE[?] に含まれる以下の 5 本である。これらは時刻を扱う代表的なユーティリティであり、過去のコードレビューにより EOD の箇所が同定されている。合計の真陽性数（ゴールドスタンダード、以降 Ngold）は 17 箇所である。

- sleep.c : sleep コマンドの実装。time_t 型の値を int 型へキャストして表示する箇所を含む（EOD 2 箇所）。
- tar.c : pax/tar アーカイバの実装。st_mtime を u_long 型にキャストして 8 進 ASCII 表現で書き出す箇所などを含む（EOD 2 箇所）。
- cpio.c : cpio アーカイバの実装。tar.c と同様のキャスト箇所を含む（EOD 4 箇所）。
- print.c : ps コマンドの出力整形ロジック。tv_sec を int 型変数 secs へ代入する箇所 6 箇所と time_t 型変数の演算結果を int 型に代入する 1 箇所（EOD 7 箇所）。
- vary.c : date コマンドのオプション処理。mktime() のリトライ条件で tm_year を 68~138 に制限するロジックを含む（EOD 2 箇所）。

4.3 評価対象モデル

本実験では Web インタフェースもしくはアプリ経由で利用可能な以下の主要な LLM を比較対象とした。予備実験を行ったうえで、本稿の本評価では特に、Microsoft Copilot (Edge ブラウザ上で Think Deeper モードを有効化)、Google Gemini 3.1 Pro, Anthropic Claude Sonnet 4.6 (Adaptive Thinking モードを有効化) の 3 モデルを取り上げる。いずれも汎用 LLM でありソースコード解析専用のチューニングは施していない。

4.4 プロンプト

前述の通り、図??に示したプロンプトを利用する。プロンプトは日本語で記述した。出力フォーマットを JSON[?] に固定することで、自然言語の混入や表記の不統一といった出力形式の揺らぎを抑え、モデル間の機械的な比較を可能とするよう工夫した。近年の LLM は JSON 形式での構造化出力機能が標準的にサポートされており[?], パースエラーを防げる利点がある。ただし、これは出力形式を一定に保つだけであり、??節で述べた応答内容の揺らぎそのものを解消するわけではない。

またプロンプトにより、式??の EOD を求めるため、式の各項目と、プロンプトを対応させる必要がある。式??とプロンプトとの対応関係を表??に示す。

ここで、Obs（観測可能性）に対して実装依存の明記を求めているのは、LP64 や LLP64 といったデータモデルの違いにより、特に long 型の変数においてエポックオーバー

表 1 式??とプロンプトの対応関係

Table 1 Eq. ??-Prompt Mapping.

式??の項目	プロンプトでの表現
Orig	指定した C 言語のソースコードから、time_t が 64 ビットであっても発生する「2038 年問題」の根本原因となる箇所を抽出し、
Trunc	time_t 型と int 型や long 型のデータ間でオーバーフローやデータの切り詰めが発生する箇所を抽出すること。
Bound	time_t が 64 ビット化されていても発生する「ロジック上の制限」を抽出すること。
Obs	実装依存の場合は、その旨を問題の種類に明記すること。

フロー欠陥（EOD）がデータフロー上で問題として顕在化（観測）するか否かが分かれるためである。LLM に実装依存の文脈を意識させることで、環境ごとの観測可能性を制御する意図がある。

4.5 評価指標

各モデルの応答について、事前に同定された EOD 箇所と一致する指摘を真陽性（True Positive, TP）、それ以外の指摘のうち EOD に該当しないものを偽陽性（False Positive, FP）として分類した。これらをもとに、適合率（Precision = $TP / (TP + FP)$ ）、再現率（Recall = $TP / Ngold$ ）、および F1 スコア（ $= 2 \cdot \text{Precision} \cdot \text{Recall} / (\text{Precision} + \text{Recall})$ ）を算出した。ここで Ngold はゴールドスタンダードの EOD 箇所数である。なお、??節で述べた通り真の再現率は算出できないため、本実験における Recall は、事前に同定されたゴールドスタンダード Ngold に対する相対的な再現率を意味する。

5. 実験結果

各ソースコードに対する各モデルの TP 数と FP 数を「TP / FP」の形式で表??に、それらから算出した Precision, Recall, F1 スコアを表??に示す。Google Gemini 3.1 Pro が 16 箇所の EOD 箇所を検出（再現率 0.94）し、かつ偽陽性数も最も少なかった。Claude Sonnet 4.6 は 13/17 箇所を検出（再現率 0.76）し、偽陽性は 3 箇所であった。Copilot は 12/17 箇所を検出（再現率 0.71）し、特に print.c における複数の tv_sec 代入箇所の検出を取りこぼした。総合的な F1 スコアでは Google Gemini 3.1 Pro が 0.94 と最も高く、Claude Sonnet 4.6 が 0.79、Copilot が 0.73 であった。

Google Gemini 3.1 Pro の F1 スコアが 0.94 であったという結果は、現時点で同モデルの総合的な検出精度の高さを示している。対象箇所を漏れなく指摘する能力に優れてい

表 2 各モデルの検出結果

Table 2 Detection results per model.

ソース	Ngold	Copilot	Gemini 3.1 Pro	Sonnet 4.6
sleep.c	2	2 / 0	2 / 0	2 / 0
tar.c	2	2 / 1	2 / 1	2 / 2
cpio.c	4	4 / 1	4 / 0	3 / 1
print.c	7	2 / 1	6 / 0	4 / 0
vary.c	2	2 / 1	2 / 0	2 / 0
合計	17	12 / 4	16 / 1	13 / 3

表 3 各モデルの検出精度

Table 3 Detection precision per model.

指標	Copilot	Gemini 3.1 Pro	Sonnet 4.6
Precision	0.75	0.94	0.81
Recall	0.71	0.94	0.76
F1	0.73	0.94	0.79

るだけでなく、誤った箇所を指摘する偽陽性も最小限に抑えられており、実用性の高い結果であった。

6. 議論

6.1 実験結果の総括

個別のソースコードについて見ると、sleep.c、tar.c、vary.c では全モデルがゴールドスタンダードを完全に検出した。tar.c では全モデルが 2 箇所の EOD を検出したが、関数定義そのもの (150 行目の ul_oct) を誤って指摘する偽陽性が発生した。print.c は tv_sec 値を int 型変数へ代入する箇所が複数 (547 行目, 571 行目, 574 行目, 585 行目, 588 行目, 604 行目) あり、モデル間の差が最も顕著であった。Copilot は 2/7 箇所しか検出できなかったのに対し、Google Gemini 3.1 Pro は 6/7 箇所を検出した。Claude Sonnet 4.6 は 4/7 箇所を検出した。

これらの結果は、時刻値への直接的な操作は全モデルが安定して検出できる一方、間接参照を付す箇所ではデータフロー追跡能力の差がモデル間の差として現れることを示唆している。以下では、LLM による問題の検出に影響するソースコード上の特徴を整理する。

まず、sleep.c、tar.c、vary.c で全モデルが検出した箇所は、時刻データに対する直接的な比較・キャスト・ビット演算や戻り値の型不一致など、いずれも確認範囲が限定されるため比較的検出が容易であると推察される。

tar.c での st_mtime に対するキャスト処理の箇所については、コンパイルスイッチにより、対象処理の有効・無効を切り替えている。このコンパイルスイッチの解釈やマクロ展開の捉え方の違いが、LLM 間での偽陽性 (FP) の指摘傾向の差 (Sonnet 4.6 のみ FP が 2 箇所など) に影響したのではないかと推察している。図??に tar.c で偽陽性の原因と考

```
402 #ifdef NET2_STAT
403     arcn->sb.st_size = (off_t)asc_ul(hd->size, sizeof(hd->size), OCT);
404     arcn->sb.st_mtime = (time_t)asc_ul(hd->mtime, sizeof(hd->mtime), OCT);
405 #else
406     arcn->sb.st_size = (off_t)asc_uqd(hd->size, sizeof(hd->size), OCT);
407     arcn->sb.st_mtime = (time_t)asc_uqd(hd->mtime, sizeof(hd->mtime), OCT);
408 #endif
```

図 5 tar.c で偽陽性の原因と考えられるコード片

Fig. 5 Suspected False-Positive Code in tar.c.

えられる、st_mtime を保持する箇所のコード片を示す。

なお、図??のプロンプトは式??の各述語を完全に表現できているわけではない。Orig については「2038 年問題の根本原因」という表現にとどまり、値が時刻意味論に由来することを明示的に確認させていない。また Obs は、??節ではコンパイルスイッチによる除外までを含む広い概念であるのに対し、今回のプロンプトでは「実装依存の場合はその旨を明記する」という指示としてしか与えておらず、コンパイルスイッチで無効化される箇所を検出対象から外す指示を明示していない。この Obs の部分的な表現が、tar.c におけるコンパイルスイッチに依存した FP を生んだ一因ではないかと考えられる。

ul_oct 関数定義そのものに対する指摘は偽陽性ではあるが、陽性の指摘箇所が、ul_oct 関数呼出し時の引数内のキャスト処理でみられることから、検出対象として挙がったものと推察する。

cpio.c については、Claude Sonnet 4.6 で 1 件検出ができなかった箇所があった。この部分は、time_t 型の値の演算結果を、time_t 型の変数に代入する処理であり、代入処理には問題は無いが、演算の中に 32 ビットの値を前提としたシフト演算がある。問題が起きるか否かは文脈により異なる部分であり、検出するか否かは判断の分かれるものと考えられる。

なお、cpio.c では、Claude Sonnet 4.6 と Copilot で、FP を 1 つずつ記録している。これは前述の検出漏れの箇所とは別に、時刻情報を 8 ビットずつ切り出して別変数に保存する処理を指摘したものである。ここが 2038 年問題につながるか否かは、別ファイルで定義されているマクロにも依存するため、人による判断が必要となる。本実験のプロンプトでは与えたファイル以外の情報を検出に用いないよう指示しているため、この箇所を検出しなかった Google Gemini 3.1 Pro の挙動は、むしろプロンプトに忠実な結果と解釈できる。したがって、当該箇所の検出を FP とすべきか否かは、ゴールドスタンダードの定義に依存する事例であり、??節で述べるゴールドスタンダードの主観性に関する脅威の具体例と位置づけられる。

また、検出結果に差が大きかった print.c には、構造体メンバの参照、代入、演算に関する処理が 6 箇所存在している。このうち 5 箇所を検出したのが、Google Gemini 3.1 Pro であり、1 箇所のみ検出したのが Copilot である。Claude Sonnet 4.6 は、6 箇所中 3 箇所検出しており、ここで結果に差が出ている。この構造体メンバはポインタ変数を経由

```
571 ^ secs = k->ki_p->ki_rusage.ru_stime.tv_sec;↓  
572 ^ psecs = k->ki_p->ki_rusage.ru_stime.tv_usec;↓  
573 ^ if (sumrusage) {↓  
574 ^     secs += k->ki_p->ki_childstime.tv_sec;↓  
575 ^     psecs += k->ki_p->ki_childstime.tv_usec;↓  
576 ^ }↓
```

図 6 print.c で問題となるコード片

Fig. 6 The problematic code snippet in print.c.

して `time_t` 型の値にアクセスするようになっており、データへの間接参照を行う処理については、LLM の特徴によって検出結果の差が大きく出るものと推察している。図 7 に `print.c` で問題を検出した、構造体メンバの例を示す。

`print.c` の 7 箇所目の問題点は、`time_t` 型の値の演算結果を、直接 `int` 型変数に代入する処理であり、これについてはすべての LLM で正しく検出している。

まとめると、LLM を用いた本手法で検出率を上げるには、以下の注意点に従うと良いと考える。

- コンパイルスイッチがあるソースコードについては、どのコードが有効になるかをプロンプト内で明示的に指示すること。
- データの間接参照についてはモデル間で検出結果に差が出ることから、複数の LLM での複数回の実験により、問題箇所の推定を行うこと。

今回は Copilot の見落としが最も多かったが、サンプル数が少なく、この結果のみで性能を論じることはできない。

6.2 従来手法との比較

筆者らはこれまでに 2038 年問題に対する二つのアプローチを報告してきた。第一は、2019 年に組込み機器の実製品開発において行った対応事例である [?]。この事例では、`time_t` 型を 32 ビットのまま維持しつつ、UNIX エポックを 28 年後に設定する（具体的には 1998 年 1 月 1 日を新たな起点とする）ことで、運用上必要となる時刻範囲を確保し、2066 年まで「延命」する手法を採用した。第二は、2023 年に報告した `time_t` 型を 64 ビット化した際に修正が必要となる箇所をコンパイラ警告の差分から抽出する手法である [?]。この手法では、64 ビット化前後でコンパイラから出力される警告（型の不整合や暗黙のキャストに関する警告）の差分を取り、かつ意図的なキャストが明示されている箇所を除外することで修正候補箇所を絞り込む。

しかし、いずれの手法も限界を持つ。延命策はあくまで暫定的対応であり、対応期限を先送りするに過ぎない。コンパイラ警告の差分による検出は、警告として顕在化する型不整合は検出できるが、`u_long` 等への明示的キャストの裏に隠されたロジック上の制約（例えば 32 ビット幅を前提とした条件式）までは検出できない。

その他プログラムスライシングやデータフロー解析 [?] は理論的には最も有力な手段だが、大規模なソフトウェア

に適用するには解析コストが大きく、セマンティクスにより問題の有無を人間が判断する必要は変わらず存在する。

2038 年問題に対しては、筆者ら以外の研究も報告されている。星名らは、`time_t` 型が 32bit を超える（64 ビット化された）環境においてもなお残存しうる 2038 年問題に着目し、その検出手法を提案している [?]。一方、矢吹らは、32bit Linux 環境を対象に、時刻同期プロトコル内で時刻変換を行うことで 2038 年問題に対処する手法を提案している [?]

本稿で提案した LLM による検出手法は、人間による判断コストを低減させる。利用モデルによる結果の不安定さは課題だが、複数モデル・複数回の試行を総合することで緩和できると考える。これにより、従来手法より問題検出の効率を向上させることが期待できる。

6.3 妥当性への脅威

式 1 で表現したモデルの妥当性、および本モデルの位置づけに対する脅威について、以下に議論する。

本モデルでは、2038 年問題の具体的な発生要因として、これまでの筆者の研究調査に基づき「値の切り詰め (Trunc)」および「暦に関する境界値の評価 (Bound)」の二つを対象としている。しかし、これらは主要な要因として抽出したものであり、2038 年問題を引き起こすあらゆる原因を網羅できているとは限らない。例えば、特定のミドルウェアやサードパーティ製ライブラリ内での暗黙的な型変換、あるいはシリアル化処理に起因するデータ構造上の不整合など、本モデルの想定外の形式で問題が顕在化する可能性（偽陰性の発生）が残されている。

また、モデル中の「外部への観測可能性 (Obs)」は、検出されたコード上の問題が実際にシステムの不具合として表面化するかを評価する上で重要な指標である。しかし、あるプログラムの実行経路において特定の状態が外部に観測可能か否かを厳密に判定する問題は、一般に「停止問題」[?]と同様に決定不能問題に帰着する。したがって、実際の検出手法において Obs を完全かつ厳密に計算することは理論上不可能であり、静的・動的解析（例：汚染経路解析や限定的なシンボリック実行など）[?]による近似に頼らざるを得ないとする。この近似の精度が、検出結果の妥当性に直接影響を与える脅威がある。

以上の脅威に基づき、本研究における式 1 は、2038 年問題の発生条件を完全に記述した「厳密な定義」ではなく、検出アプローチを体系化し、現実的な解析範囲を定めるためのヒューリスティックな概念的・運用的モデルとして位置づけるのが妥当である。今後は、実験評価を通じて未知の要因をフィードバックしモデルを拡張すること、および Obs の現実的な近似手法の洗練を図ることが課題となる。

さらに、本実験の内的妥当性に関わる脅威として、ゴールドスタンダード (17 箇所) の同定が筆者らの過去のコー

ドレビューに基づく主観的判断に依拠している点が挙げられる。あるコード片に対して EOD に該当すると判定すること自体がプログラムのセマンティクスに依存するため、境界的な事例では誰が判断したかによって解釈が分かれ得る。また、各モデルの応答を TP / FP に分類する際も同一のゴールドスタンダードを基準とするため、ゴールドスタンダードに誤りや見落としがあれば、適合率・再現率の双方が系統的に偏る恐れがある。この脅威を低減するには、複数のレビュー者による独立な判定とその一致度に基づくゴールドスタンダードの構築や、EOD 該当性の判定基準を明文化したうえでの再検証が望ましい。

また、評価に使用したデータセット^{*1}が 5 ファイル 17 箇所と小規模であり、より大規模なソースコード群では検出精度が変動しうるため、一般化可能性にはさらなる検証が必要である。また、本実験は各モデルにつき 1 回の試行に基づく結果であり、??節で述べた応答の揺らぎの影響は評価していない。さらに、結果は使用した LLM の特定のバージョンに依存し、基盤モデルの更新や確率的な非決定性により同一条件下でも再現されない可能性がある。したがって本節の数値は速報的な位置づけであり、複数回試行による再現性・ロバスト性の検証は今後の課題である。

7. おわりに

本研究では、今後到来する 2038 年問題の対策として、ソースコード中から潜在的な問題箇所を効率的に検出するための手法について検討を行った。2038 年問題の発生メカニズムを体系化し、時刻起源 (Orig)、値の切り詰め (Trunc)、暦に関する境界値の評価 (Bound)、および外部への観測可能性 (Obs) の論理式として表現する概念的モデルを提案した。さらに、本モデルに基づく問題箇所の識別能力を検証するため、大規模言語モデル (LLM) を用いた評価実験を行い、提案モデルの有用性と LLM による検出の可能性を示した。

今後の課題としては、提案モデルおよび LLM による検出精度のさらなる定量的な評価と改善が挙げられる。今後は、実際に Trunc や Bound の不具合を含む OSS のコード断片を広く収集し、評価用のゴールドスタンダードを拡充する。この拡充したデータセットを用いて LLM のプロンプトエンジニアリングやファインチューニング等の最適化を図り、より多様なコードパターンに対しても高精度に 2038 年問題箇所を特定できるアプローチの確立を目指す。また、本実験では LLM による候補検出の精度のみを評価しており、LLM による支援を加えた人間のレビューを組み合わせたワークフロー全体でのレビューコスト削減効果の検証も行いたい。

参考文献

- [1] IEEE: The Open Group Base Specifications Issue 7, 2018 edition / IEEE Std 1003.1-2017, IEEE (2018).
- [2] ISO: ISO/IEC 9899:2024 Information technology – Programming languages – C, International Organization for Standardization (2024).
- [3] The FreeBSD Project: FreeBSD 13.2-RELEASE Release Notes (2023).
- [4] Chen, M., et al.: Evaluating Large Language Models Trained on Code, arXiv preprint arXiv:2107.03374 (2021).
- [5] Jain, N., et al.: LiveCodeBench: Holistic and Contamination Free Evaluation of Large Language Models for Code, arXiv preprint arXiv:2403.07974 (2024).
- [6] Liu, P., et al.: Pre-train, Prompt, and Predict: A Systematic Survey of Prompting Methods in Natural Language Processing, ACM Computing Surveys, Vol. 55, No. 9, Article 195 (2023).
- [7] Song, Y., Wang, G., Li, S., Lin, B. Y.: The Good, The Bad, and The Greedy: Evaluation of LLMs Should Not Ignore Non-Determinism, arXiv preprint arXiv:2407.10457 (2024).
- [8] Bray, T.: The JavaScript Object Notation (JSON) Data Interchange Format, RFC 8259, IETF (2017).
- [9] OpenAI: Structured model outputs, <https://developers.openai.com/api/docs/guides/structured-outputs> (参照 2026-06-15).
- [10] 大江秀幸, 安藤友康, 松下誠, 井上克郎: 組込み機器開発における 2038 年問題への対応事例, デジタルプラクティス, Vol. 10, No. 3 (2019).
- [11] 大江秀幸, 松下誠, 井上克郎: コンパイラ警告を利用したデータ型変更時の影響範囲確認方法の提案, 情報処理学会研究報告, Vol. 2023-SE-215, No. 4, pp. 1-8 (2023).
- [12] Weiser, M.: Program Slicing, IEEE Transactions on Software Engineering, Volume 10, Issue 4, pp. 352-357 (1984).
- [13] 星名藍乃介, 穂山空道, 上原哲太郎: 32bit を超える time_t 型を持つ環境における 2038 年問題とその検出, 情報処理学会論文誌, Vol. 65, No. 9, pp. 1387-1398 (2024).
- [14] 矢吹潤, 岡部亮, 堀井圭祐, 外山正勝: 時刻同期プロトコル内の時刻変換による 32bit Linux の 2038 年問題対策, FIT2019 講演論文集第 1 分冊, pp. 151-152 (2019).
- [15] Sipser, M. (渡辺治, ほか訳): 計算理論の基礎 [原著第 3 版] 2. 計算可能性の理論, 共立出版 (2023).
- [16] Schwartz, E. J., Avgerinos, T., Brumley, D.: All You Ever Wanted to Know about Dynamic Taint Analysis and Forward Symbolic Execution (but Might Have Been Afraid to Ask), Proc. IEEE Symposium on Security and Privacy, pp. 317-331 (2010).

^{*1} <https://github.com/hide-work/y2038-llm-dataset> にて本実験で用いたデータセットを公開している。